

**FACULDADE DE TECNOLOGIA DE SÃO JOSÉ DOS CAMPOS
FATEC PROFESSOR JESSEN VIDAL**

ANA CRISTINA DE PAULA LIMA

**APLICAÇÃO DE REDE NEURAL PARA COMPRESSÃO
DOS DADOS DO SATÉLITE GOES16**

São José dos Campos
2019

ANA CRISTINA DE PAULA LIMA

**APLICAÇÃO DE REDE NEURAL PARA COMPRESSÃO
DOS DADOS DO SATÉLITE GOES16**

Trabalho de Graduação apresentado à
Faculdade de Tecnologia de São José dos
Campos, como parte dos requisitos
necessários para a obtenção do título de
Tecnólogo em Análise e Desenvolvimento
de Sistemas.

Orientador Interno ou Orientador: Prof.º Me. Emanuel Mineda Carneiro
Orientador Externo ou Coorientador: Dr.º Alex Sandro Aguiar Pessoa

São José dos Campos
2019

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

DE PAULA LIMA, Ana Cristina
Aplicação de rede neural para compressão dos dados do satélite GOES16.
São José dos Campos, 2019.
30f.

Trabalho de Graduação – Curso de Tecnologia em Análise e Desenvolvimento de Sistemas.
FATEC de São José dos Campos: Professor Jessen Vidal, 2019.
Orientador Interno ou Principal: Prof.º Me. Emanuel Mineda Carneiro.
Orientador Externo ou Coorientador: Dr.º Alex Sandro Aguiar Pessoa.

1. Inteligência Artificial 2. Redes Neurais. 3. Machine Learning. I. Faculdade de Tecnologia.
FATEC de São José dos Campos: Professor Jessen Vidal. Divisão de Informação e
Documentação. II. Aplicação de rede neural para compressão dos dados do satélite GOES16.

REFERÊNCIA BIBLIOGRÁFICA

DE PAULA LIMA, Ana Cristina. Aplicação de rede neural para compressão dos dados do satélite GOES16. 2019. 30f. Trabalho de Graduação - FATEC de São José dos Campos: Professor Jessen Vidal.

CESSÃO DE DIREITOS

NOME(S) DO(S) AUTOR(ES): Ana Cristina de Paula Lima

TÍTULO DO TRABALHO: Aplicação de rede neural para compressão dos dados do satélite GOES16.

TIPO DO TRABALHO/ANO: Trabalho de Graduação/2019.

É concedida à FATEC de São José dos Campos: Professor Jessen Vidal permissão para reproduzir cópias deste Trabalho e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte deste Trabalho pode ser reproduzida sem a autorização do autor.

Ana Cristina de Paula Lima
Rua Doutor Alfredo Amaral Rocha, 50,
Maria Elmira
12285-150, Caçapava - SP

ANA CRISTINA DE PAULA LIMA

**APLICAÇÃO DE REDE NEURAL PARA COMPRESSÃO
DOS DADOS DO SATÉLITE GOES16**

Trabalho de Graduação apresentado à
Faculdade de Tecnologia de São José dos
Campos, como parte dos requisitos
necessários para a obtenção do título de
Tecnólogo em Análise e Desenvolvimento
de Sistemas.

Prof.º Me. Emanuel Mineda Carneiro – Fatec Prof.º Jessen Vidal

Dr.º Alex Sandro Aguiar Pessoa - CLIMATEMPO

Titulação, Nome do Componente da Banca - Sigla da Instituição

Titulação, Nome do Componente da Banca - Sigla da Instituição

____/____/____

DATA DA APROVAÇÃO

AGRADECIMENTOS

Agradeço à FATEC Professor Jessen Vidal e ao Centro Paula Souza pela disponibilização de cursos de qualidade, com foco em inovações tecnológicas disponíveis.

Ao Dr.º Alex Sandro Aguiar Pessoa pela ideia e orientação durante o estudo e ao Prof.º Me. Emanuel Mineda Carneiro pela orientação e sugestão de melhorias no trabalho.

Aos demais professores por toda a dedicação, paciência e conhecimentos compartilhados.

À minha família, aos meus amigos e a todos que de alguma forma participaram dessa etapa, apresento-lhes meu sincero agradecimento por todo o apoio e suporte.

“A dúvida é o princípio da sabedoria.”

Aristóteles

RESUMO

A Climatempo é uma empresa que presta consultoria na área de meteorologia e possui produtos voltados para a área do agronegócio e alertas meteorológicos. Teve o seu início da década de 1980 e atualmente foi adquirida pelo grupo norueguês StormGeo. Atualmente os dados utilizados para gerar as previsões são aqueles provenientes de satélites meteorológicos, em específico o satélite GOES16, que é um satélite de órbita geoestacionário, ou seja, acompanha a rotação da Terra em torno do seu próprio eixo. O GOES16 atualmente é mantido pela NOAA, que é a instituição de pesquisa americana responsável por administrar satélites meteorológicos. Os dados são obtidos através de uma antena do GEONETCast, rede mundial que tem como intuito prover informações de satélite por um baixo custo para países em desenvolvimento, sendo então armazenados no servidor da Climatempo. Os dados podem ser divididos entre, dados observacionais, que são dados sem manipulação obtidos via satélite e, dados de previsão, que são dados que já sofreram alterações dos meteorologistas, gerando o modelo utilizado para previsões. O envio das imagens via satélite ocorrem entre 15 minutos a 30 minutos, ou seja, seu volume de armazenamento é extramente alto, levando-se em consideração que os arquivos possuem *mega bytes* de extensão. O objetivo do estudo em si está em analisar a viabilidade de se utilizar redes neurais para compactar estas imagens de forma eficiente, realizando a sua descompactação quando for necessária, com o mínimo possível de perda na qualidade da imagem.

Palavras-Chave: Redes Neurais; Inteligência Artificial; Autoencoder; Python; TensorFlow.

ABSTRACT

Climatempo is a company that provides consulting in the area of meteorology and has products focused on the agribusiness area automatic and meteorological alerts. It began in the 1980s and was recently acquired by the Norwegian group StormGeo. The data used to generate the evidence are meteorological satellites, specifically the satellite GOES16, which is a satellite of geostationary orbit, that is, it is accompanied by a rotation of the Earth on its own axis. The GOES16 is currently maintained by NOAA, which is a leading institution of the American standard responsible for the management of meteorological satellites. The data is obtained through a GEONETCast antenna, a worldwide network that is intended to provide satellite information for a lower cost to developing countries and is then stored on the Climatempo server. The data can be divided between observational data, which are given without due occurrence through satellite and, forecast data, which are data that undergo the changes of the meteorologists, generating the model used for predictions. The sending of the satellite images between 15 minutes to 30 minutes, that is, its storage volume is extra high, taking into account the files that have mega bytes in extension. The study is a study is a study using the virtual efficiency for making off in a quality of images.

Keywords: Neural Networks; Artificial intelligence; Self-contain; Python; TensorFlow.

LISTA DE FIGURAS

Figura 1 – Classe Autoencoder.....	27
Figura 2 – Utilização da função autoencoder em um dataset.....	27
Figura 1 – Resultados obtidos (Entradas acima, saídas abaixo).....	27

LISTA DE TABELAS

Tabela 1 - População de 15 a 24 anos de idade.....	17
--	----

LISTA DE ABREVIATURAS E SIGLAS

API	<i>Application programming interface</i>
CMA	<i>Chinese Meteorological Administration</i>
EUMETSAT	<i>European Organisation for the Exploitation of Meteorological Satellites</i>
GOES	<i>Geostationary Operational Environmental Satellites</i>
MB	<i>Mega bytes</i>
NOAA	<i>National Oceanic Atmospheric Administration</i>

LISTA DE SÍMBOLOS

μm	Micrómetro
---------------	------------

SUMÁRIO

1. INTRODUÇÃO.....	14
1.1. Objetivos Geral.....	14
1.2. Objetivos Específicos.....	15
1.3. Abordagem Metodológica.....	15
2. REVISÃO DA LITERATURA.....	17
2.1. Clima.....	17
2.2. Meteorologia.....	17
2.3. Satélite.....	18
2.3.1. Satélite meteorológico.....	18
2.3.2. Órbita geoestacionária.....	19
2.3.3. Órbita polar.....	20
2.4. NOAA.....	21
2.5. GOES16.....	21
2.5.2. Canal Visível.....	22
2.5.1. Canal Infravermelho.....	22
2.5.3. Canal de Vapor d'água.....	22
2.6. GEONETCAST.....	23
2.7. Redes Neurais.....	24
2.8. Python.....	24
2.9. Tensorflow.....	25
2.10. Autoencoders.....	25
3. DESENVOLVIMENTO DO TRABALHO.....	26
3.1. Exemplo de Autoencoder utilizando Tensorflow.....	26
4. RESULTADOS E DISCUSSÕES.....	28
4.1. Resultado da compressão de imagens.....	28
5. CONSIDERAÇÕES FINAIS.....	29
2.3. Conclusão.....	29
2.4. Trabalhos futuros.....	29
REFERÊNCIAS BIBLIOGRÁFICAS.....	30

1. INTRODUÇÃO

A Climatempo é uma empresa de consultoria meteorológica, com sede em São Paulo e extensão em São José dos Campos – SP.

Seus produtos são únicos e exclusivamente voltados para a geração de dados meteorológicos, portanto, é de extrema importância que esta utilize dados sempre atualizados, dados estes provenientes de estações meteorológicas e principalmente de satélites, tendo como principal o satélite GOES16.

Satélites de órbita geoestacionárias, como é o caso do GOES16, são satélites que acompanham a rotação da Terra em torno do seu próprio eixo, capturando diversas informações da superfície terrestre e atmosférica através de seus canais infravermelho, visível e vapor d'água.

As informações enviadas são capturadas pela Climatempo através da antena do GEONETCast, rede mundial que provém informações meteorológicos com baixo custo para os seus usuários. Essas informações chegam a cada 15 minutos ou meia hora, ocasionando o armazenamento massivo de dados, cuja extensão equivale a MB (*Mega Bytes*).

Com intuito de reduzir os custos da empresa com esse armazenamento, será feito um estudo com redes neurais artificiais aplicado as imagens armazenadas, para a realização da compactação automática destas, sem perdas significativas de seu conteúdo.

Utilizando-se da linguagem de programação Python, que atualmente vem sendo muito utilizada para estudos sobre aprendizado de máquina e redes neurais profundas, e da sua biblioteca para inteligência artificial denominada TensorFlow, espera-se resultados significativos em relação aos objetivos propostos.

1.1. Objetivo do Geral

O objetivo geral deste trabalho é realizar a compressão, utilizando redes neurais, das imagens geradas pela Climatempo após a obtenção e tratamento dos dados via satélite GOES16, resultando em arquivos menores sem perda de qualidade. A Climatempo, empresa de consultoria meteorológica localizada em São José dos Campos com sede em São Paulo, utiliza estas imagens para gerar as previsões meteorológicas.

Atualmente as imagens geradas após o tratamento dos dados obtidos pelo satélite chegam a ocupar *terabytes* de memória, o que torna o seu armazenamento caro e a sua veiculação lenta.

1.2. Objetivos Específicos

Para a consecução deste objetivo foram estabelecidos os objetivos específicos:

- Levantar informações sobre os dados obtidos via satélite GOES16, tais como, formato obtido e local de armazenamento;
- Levantar informações sobre os dados observacionais gerados a partir dos dados obtidos via satélite GOES16, tais como, formato obtido e local de armazenamento;
- Realizar um estudo sobre redes neurais e a sua aplicabilidade na resolução do problema;
- Levantar informações sobre as tecnologias que melhor se adequam à resolução do problema;
- Desenvolvimento de um protótipo de teste para verificar a viabilidade de se utilizar ou não redes neurais para a compressão dos dados;
- Comprovar se a aplicabilidade de redes neurais para este fim é viável ou não através dos resultados obtidos.

1.3. Abordagem Metodológica

Para atender aos objetivos deste trabalho, a metodologia de pesquisa utilizada será estruturada em exploratória e quantitativa, pois será realizado um estudo de viabilidade em um campo ainda não explorado pela empresa e com os resultados obtidos será possível mensurar se a sua aplicabilidade é viável ou não.

Os dados utilizados serão os dados captados pelo satélite GOES16 (*Geostationary Operational Environmental Satellites*) armazenados hoje pela Climatempo para a realização da previsão meteorológica.

Os dados se dividem entre, dados observados, que são dados brutos obtidos diretamente dos satélites e, dados de previsão, que são os dados alterados pelos meteorologistas, também denominados “modelos” meteorológicos.

A utilização de inteligência artificial aplicada a captação de padrões para análise de imagens vem sendo amplamente difundida atualmente, e a escolha pela linguagem Python

se deve a sua extensa lista de bibliotecas que foram desenvolvidas especialmente para estes propósitos científicos.

Através dos estudos utilizando-se de redes neurais artificiais aplicadas às imagens captadas com estruturas semelhantes entre si que a Climatempo possui, será possível definir se esta é a melhor alternativa na escolha desta tecnologia com o propósito reduzir custos da empresa.

2. REVISÃO DA LITERATURA

Neste capítulo serão revistos textos que subsidiem os conhecimentos necessários ao entendimento do trabalho apresentado. A contextualização dos referentes assuntos apresenta-se em tópicos resumidos que tratam da importância de cada elemento que será utilizado de base para o estudo.

2.1. Climatempo

A Climatempo é uma empresa brasileira que oferece serviços e consultoria na área de meteorologia, com sede na Vila Mariana em São Paulo e uma extensão tecnológica localizada em São José dos Campos.

Fundada na década de 1980 pelos meteorologistas Carlos Magno e Ana Lúcia Frony, a empresa iniciou com um capital de USD 10.000,00 em 1988 e em 2013 (25 anos depois) já possuía faturamento anual em torno de 17 milhões de reais.

A Climatempo possui diversos serviços, sendo estes um portal e um aplicativo interativo com previsões e boletins meteorológicos para as regiões brasileiras, produtos exclusivos voltados para o agronegócio, emissão de alertas e boletins personalizados de acordo com as necessidades do cliente, API de dados meteorológicos e um canal de TV informativo e interativo homônimo.

A empresa foi adquirida em 51% pela empresa norueguesa StormGeo em 18 de fevereiro de 2019, juntamente com a percentagem de 30% da TV Climatempo.

2.2. Meteorologia

A meteorologia é a ciência que abrange profundamente o estudo sobre os fenômenos atmosféricos através de seus processos físicos, químicos e dinâmicos e como se dá a interação destes processos com os sistemas litosfera, hidrosfera, criosfera e biosfera, sendo, portanto, inserida no âmbito das Ciências Ambientais. Sua aplicação é extensa e influencia nas atividades humanas e condições humanas, como por exemplo, no ramo da agricultura, vestuário, saúde, aviação, recursos hídricos, entre outros. (YNOUE et al., 2017).

O termo meteorologia foi utilizado pelo filósofo grego Aristóteles, que, por volta de 350 a.C., em sua obra intitulada Meteorologia, descreveu os primeiros conhecimentos sobre tempo e clima da época, de maneira filosófica e especulativa. Naquela época, todas as observações ocorridas na atmosfera eram chamadas de meteoros, o que explica o tempo meteorologia. Apenas a partir do século XV, quando surgiram os primeiros instrumentos meteorológicos, a Meteorologia adquiriu

caráter de ciência natural. Desde então, vem avançando o desenvolvimento de instrumentos de observação de dados meteorológicos, transmissão, análise e previsão. (YNOUE et al., 2017, p. 8).

A partir da década de 1950, com o surgimento dos computadores, tornou-se possível a realização de previsões climáticas em um curto prazo de tempo mediante a resolução de um grande número de equações que descrevem o comportamento da atmosfera. Em 1960, com o lançamento do primeiro satélite meteorológico, foi possível iniciar os registros das informações meteorológicas de todo o globo terrestre. (YNOUE et al., 2017).

Atualmente, o avanço da tecnologia tem possibilitado as previsões a longo prazo e análises de quais os efeitos causados pelas mudanças no meio ambiente.

2.3. Satélite

Satélites são objetos que giram entorno de outros objetos, e são classificados em dois tipos: naturais e artificiais.

Satélite natural se refere àquele que não foi construído pelo ser humano, como por exemplo, a Lua, que pode ser considerada um satélite natural pois gira em volta da Terra. (FLORENZANO, 2008).

Satélite artificial, como o próprio nome sugere, são aqueles provenientes do engenho humano, cuja finalidade pode ser a de percorrer em volta da Terra ou outro astro. (FLORENZANO, 2008).

O caminho pelo qual o satélite percorre é denominado órbita, e o tipo de órbita escolhida para alocar um satélite é definida pela inclinação e o tempo de giro completo em torno da Terra deste. (FLORENZANO, 2008).

2.3.1. Satélite meteorológico

Satélites meteorológicos são estações dotadas de câmeras que são utilizadas para fotografar os sistemas nebulosos da superfície terrestre. A partir do momento em que há o registro das fotos, estas são enviadas para a Terra em um curto período de tempo. Com a captação destas fotos é possível realizar previsões de tempo desde algumas horas até alguns dias. (PRADO; KUGA, 2001).

A importância desse tipo de satélite se dá por conta da sua utilização em atividades humanas que dependem do tempo, como por exemplo, a agricultura, e para a evacuação de locais que podem ser afetados por desastres naturais climáticos, como por exemplo, furacões e fortes tempestades, devido a capacidade de se prever a trajetória destes. (PRADO; KUGA, 2001).

2.3.2. Órbita geoestacionário

Órbitas geoestacionárias são satélites equatoriais que ficam permanentemente sobre a linha do equador e que apresentam o período de rotação coincidente com o período de rotação da Terra, portanto giram na mesma velocidade. (TEIXEIRA, 2019).

Este satélite pode observar uma região circular com um raio aproximado de até 70° de latitude, porém, sua observação é limitada devido às deformações referentes à curvatura da Terra. (TEIXEIRA, 2019).

Os satélites de comunicação e os meteorológicos giram em órbitas geoestacionárias, muito distantes da Terra, a cerca de 36.000 quilômetros de altitude.

Esse tipo de órbita é apropriado para esses satélites, pois permite manter sua antena apontada sempre para uma mesma região da Terra e assim captar e transmitir dados com grande frequência e de extensas áreas. (FLORENZANO, 2008, p. 24).

Uma órbita do tipo geoestacionário possui a importante característica de que os satélites colocados nela permaneçam fixos em relação a um observador, também fixo, na Terra. Isso ocorre por conta do período de rotação desta órbita ser o mesmo que o período de rotação da Terra sob o seu próprio eixo, fazendo com que ambos girem no mesmo espaço com a mesma velocidade angular. (PRADO; KUGA, 2001).

Atualmente a Terra possui um cinturão aonde esses satélites podem ser alocados, o que gera preocupações devido o satélite possuir um tamanho finito e haver a necessidade de um espaçamento mínimo entre eles. Conclui-se então que a quantidade de satélites geoestacionários em um determinado período de tempo seja finita. (PRADO; KUGA, 2001).

2.3.3. Órbita polar

A órbita polar se refere àquela que está paralela ao eixo da Terra e que possui uma inclinação de 90 graus, o que permite a passagem do satélite por todo o planeta de forma sincronizada com o movimento da Terra em torno do Sol. (FLORENZANO, 2008).

Satélites deste tipo passam pelos polos ou próximo deles, e o período de suas órbitas são entre uma a duas horas. Entre duas passagens pelo equador este satélite passa por novas regiões nas quais o Sol está aproximadamente na mesma posição que na sua passagem anterior, isto faz com que ele observe a Terra em pontos que possuem o mesmo tipo de iluminação. (TEIXEIRA, 2019).

Por conta dos satélites desta órbita passarem pelo mesmo local duas vezes a cada 12 horas, com dois satélites é possível obter informações sobre a Terra quatro vezes por dia.

Devido ao fato dos satélites enviarem imagens da Terra a cada 30 minutos, são extremamente úteis para monitorar uma série de eventos que necessitam de dados contínuos, como por exemplo, fenômenos atmosféricos, formação e o desenvolvimento das nuvens, temperatura da superfície terrestre, vapor d'água, entre outros. (EMBRAPA, 2019).

2.4. NOAA

NOAA (*National Oceanic Atmospheric Administration*) é a instituição governamental americana responsável por manter os satélites meteorológicos a partir da década de 1970, dentre eles temos os satélites da série NOAA e GOES (*Geostationary Operational Environmental Satellites*).

Esta instituição faz parte do departamento de comércio dos Estados Unidos e é responsável por assuntos ligados à meteorologia, oceanos, atmosfera e clima.

2.5. GOES16

O GOES16 faz parte da série de satélites GOES (*Geostationary Operational Environmental Satellites*) sendo estes responsáveis por oferecer imagens regularmente para serem utilizadas pelos serviços de previsão dos países localizados no continente americano. (EMBRAPA, 2019).

A rede de satélites GOES teve início na década de 1970 e desde de 1975 já colocou em órbita 15 satélites.

Satélites GOES possuem 5 canais espectrais, sendo um Visível (0,55-0,75 μm), três canais Infravermelhos (3,8-4,0 μm , 10,2-11,2 μm , 11,5-12,5 μm) e um canal de Vapor d'Água (6,5-7,0 μm), com as respectivas resoluções de 1 quilômetros, 4 quilômetros e 8 quilômetros. (TEIXEIRA, 2019).

Em 2016 o centro de pesquisas de instituição denominado NOAA (*National Oceanic Atmospheric Administration*) anunciou sobre o deslocamento do satélite geoestacionário GOES16 para a posição leste a 75 graus de longitude oeste, em uma altitude de 35.888 quilômetros acima da linha do Equador, favorecendo a América do Sul. (CLIMATEMPO, 2017).

Este satélite se destaca por ser o primeiro com detector de raios que ficará em órbita geoestacionária. Através deste instrumento é possível mapear os raios entre nuvens e de nuvens para o solo, auxiliando desta forma os meteorologistas a detectarem tempestades severas com antecedência.

2.5.1 Canal visível

Em resumo, trata-se da imagem com maior resolução espacial, no canal visível a radiação solar é refletida pela superfície da atmosfera e os comprimentos de onda presentes vão do verde-amarelo passando pelo laranja-vermelho, dessa forma, as imagens neste canal representam a intensidade do brilho percebida aos olhos humanos.

Neste canal as nuvens espessas são mais brilhantes porque refletem mais luz solar, de fato, há melhor aproveitamento das imagens geradas pelo canal visível quando há reflexão da luz solar, pois quando o sol está baixo, as imagens geradas por esse canal são mais escuras. (YAMASOE, 2012).

2.5.2 Canal infravermelho

No canal infravermelho a radiação é emitida pela superfície e pela atmosfera e há medições no período noturno.

Os dados gerados a partir deste canal são comumente utilizados para a observação das propriedades térmicas e atmosféricas da Terra e também para a localização de áreas de gelo. Por conta da superfície terrestre emitir radiação infravermelha em maior intensidade, as imagens geradas representam a superfície terrestre e o topo das nuvens, prevendo dessa forma tempestades, pois nuvens altas podem indicar forte atividade convectiva. (FERNANDES, 2010)

2.5.3 Canal de vapor d'água

No canal de vapor d'água há disponibilidade de imagem em qualquer horário do dia, suas imagens são utilizadas para a observação de padrões de larga escala durante a ausência de nuvens. (YAMASOE, 2012).

A radiação em torno da faixa de onda de $6.5 \mu\text{m}$ é absorvida assim como emitida pelo vapor d'água. O canal de vapor d'água (WV) de satélites meteorológicos trabalha em torno deste comprimento de onda. O canal WV detecta o vapor d'água no ar, principalmente em torno de 10.000 a 40.000 pés acima da superfície terrestre. O nível de brilho da imagem obtida nesta faixa indica a quantidade de umidade presente na atmosfera. (FERNANDES, 2010)

2.6. GEONETCast

GEONETCast é uma rede mundial de sistemas para disseminar informações provenientes de satélites, em tempo quase real. Sua projeção se deve ao fato de distribuir dados observados, da superfície terrestre, da atmosfera, além de metadados e produtos para diferentes tipos de usuário, entre eles, para os que vivem em países em desenvolvimento, principalmente África, América Latina e Ásia.

A tecnologia de recepção utilizada pelo GEONETCast é baseada em componentes comuns e disponíveis no mercado, o que garante a sua ampla adoção por um custo baixo.

Seu serviço de disseminação de informações de baixo custo tem como objetivo fornecer informações completas que possam auxiliar na tomada de decisões conscientes para diferentes áreas, tais como, saúde pública, energia, agricultura, desastres naturais, ecossistemas, entre outros.

O GEONETCast é comandado por três provedores de infraestrutura: EUMETSAT (*European Organisation for the Exploitation of Meteorological Satellites*) na Europa, CMA (*Chinese Meteorological Administration*) na região Ásia-Pacífico e a NOAA (*National Oceanic Atmospheric Administration*) no Hemisfério Ocidental. (CPTEC - INPE, 2018).

2.7. Redes neurais artificiais

Redes neurais artificiais são modelos computacionais baseados no sistema nervoso dos seres vivos, onde o número de interconexões que ligam os neurônios artificiais são representados por vetores/matrizes. (SILVA; SPATTI; FLAUZINO, 2010).

São capacitados para adquirir e manter conhecimento, com base em informações, podendo ser definidas como um conjunto de unidades de processamento.

Suas características principais são: Adaptação por experiência, capacidade de aprendizado, habilidade de generalização, organização de dados, tolerância a falhas, armazenamento distribuído e facilidade de prototipagem.

2.8. Python

Python é uma linguagem de programação de alto nível e interpretada, que possui tipagem dinâmica e forte e foi desenvolvida por Guido van Rossum em 1991. Os objetivos para com esse projeto eram: produtividade e legibilidade. Entre as suas principais características se destacam o fato do baixo uso de caracteres especiais, o que a torna muito

próxima do pseudo-código e a utilização de indentação para marcar os blocos, o que mantém o código muito mais limpo e legível.

A origem do nome se deve ao filme satírico inglês denominado *Monty Python's Flying Circus*, contando hoje com uma comunidade extremamente ativa.

Sua utilização nas áreas científicas vêm avançando rapidamente, devido a sua boa legibilidade e a extensa quantidade de bibliotecas que possui para tais fins.

2.9. TensorFlow

TensorFlow é uma biblioteca Python de código aberto que pode ser representada como um grafo de fluxo de dados, onde os nós neste grafo são considerados operações matemáticas enquanto suas bordas são dados que se comunicam de um nó para outro. Os dados gerados por essa biblioteca são representados como tensores, que são vetores multidimensionais.

Essa biblioteca é muito utilizada na prática de aplicações voltadas para aprendizagem de máquina e redes neurais profundas, embora também seja utilizada em uma ampla variedade de outras áreas.

2.10. Autoencoders

Autoencoder, com a tradução literal para codificador automático, é um tipo de rede neural treinada para realizar a cópia de uma entrada para uma saída, porém, não de forma perfeita. A cópia é feita somente com dados que se assemelham entre si conforme é realizado o treinamento da rede neural, dessa forma, a geração da saída é forçada a priorizar somente alguns aspectos da entrada, ou seja, essa rede aprende somente propriedades úteis dos dados.

3. DESENVOLVIMENTO DO TRABALHO

O algoritmo abaixo representa como é feita a compressão e descompressão de imagens e o resultado final obtido.

Figura 1 – Classe Autoencoder.

```
1  from tensorflow.keras.layers import Dense, Input
2  from tensorflow.keras.models import Model
3
4  class Autoencoder(object):
5
6      def __init__(self, inout_dim, encoded_dim):
7          input_layer = Input(shape=(inout_dim,))
8          hidden_input = Input(shape=(encoded_dim,))
9          hidden_layer = Dense(encoded_dim, activation='relu')(input_layer)
10         output_layer = Dense(784, activation='sigmoid')(hidden_layer)
11
12         self._autoencoder_model = Model(input_layer, output_layer)
13         self._encoder_model = Model(input_layer, hidden_layer)
14         tmp_decoder_layer = self._autoencoder_model.layers[-1]
15         self._decoder_model = Model(hidden_input, tmp_decoder_layer(hidden_input))
16
17         self._autoencoder_model.compile(optimizer='adadelta', loss='binary_crossentropy')
18
19     def train(self, input_train, input_test, batch_size, epochs):
20         self._autoencoder_model.fit(input_train,
21                                     input_train,
22                                     epochs = epochs,
23                                     batch_size=batch_size,
24                                     shuffle=True,
25                                     validation_data=(
26                                         input_test,
27                                         input_test))
28
29     def getEncodedImage(self, image):
30         encoded_image = self._encoder_model.predict(image)
31         return encoded_image
32
33     def getDecodedImage(self, encoded_imgs):
34         decoded_image = self._decoder_model.predict(encoded_imgs)
35         return decoded_image
36
```


Fonte: Ways to Implement Autoencoders with TensorFlow and Python. (2018).

Figura 2 – Utilização da função autoencoder em um dataset.

```
1 import numpy as np
2 from tensorflow.keras.datasets import fashion_mnist
3 from autoencoder_keras import Autoencoder
4 import matplotlib.pyplot as plt
5 import os
6 os.environ['TF_CPP_MIN_LOG_LEVEL'] = '2'
7
8 # Import data
9 (x_train, _), (x_test, _) = fashion_mnist.load_data()
10
11 # Prepare input
12 x_train = x_train.astype('float32') / 255.
13 x_test = x_test.astype('float32') / 255.
14 x_train = x_train.reshape((len(x_train), np.prod(x_train.shape[1:])))
15 x_test = x_test.reshape((len(x_test), np.prod(x_test.shape[1:])))
16
17 # Keras implementation
18 autoencoder = Autoencoder(x_train.shape[1], 32)
19 autoencoder.train(x_train, x_test, 256, 50)
20 encoded_imgs = autoencoder.getEncodedImage(x_test)
21 decoded_imgs = autoencoder.getDecodedImage(encoded_imgs)
22
23 # Keras implementation results
24 plt.figure(figsize=(20, 4))
25 for i in range(10):
26     # Original
27     subplot = plt.subplot(2, 10, i + 1)
28     plt.imshow(x_test[i].reshape(28, 28))
29     plt.gray()
30     subplot.get_xaxis().set_visible(False)
31     subplot.get_yaxis().set_visible(False)
32
33     # Reconstruction
34     subplot = plt.subplot(2, 10, i + 11)
35     plt.imshow(decoded_imgs[i].reshape(28, 28))
36     plt.gray()
37     subplot.get_xaxis().set_visible(False)
38     subplot.get_yaxis().set_visible(False)
39 plt.show()
40
```

Fonte: Ways to Implement Autoencoders with TensorFlow and Python. (2018).

Figura 3 – Resultados obtidos (Entradas acima, saídas abaixo).



Fonte: Ways to Implement Autoencoders with TensorFlow and Python. (2018).

4. RESULTADOS E DISCUSSÕES

Nesta fase será realizada uma análise crítica dos resultados obtidos, comparando com os esperados e os visualizados na Revisão da Literatura.

Em relação a formatação, deve seguir o mesmo padrão do item 1. INTRODUÇÃO.

4.1. Título 4.1

Texto.....

4.2. Título 4.2

Texto.....

5. CONCLUSÃO

Esta é a parte final do trabalho, referindo-se às hipóteses discutidas anteriormente.

A conclusão é uma resposta para a problemática do tema proposto na introdução, com base nos resultados que o(s) autor(es) avaliou e interpretou.

Em relação a formatação, deve seguir o mesmo padrão do item 1. INTRODUÇÃO.

REFERÊNCIAS BIBLIOGRÁFICAS

3 Ways to Implement Autoencoders with TensorFlow and Python. 2018. Disponível em: <<https://rubiksgcode.net/2018/11/26/3-ways-to-implement-autoencoders-with-tensorflow-and-python/>>. Acesso em: 14 jun. 2019.

CLIMATEMPO. **GOES-16 verá América do Sul com maior precisão:** Satélite meteorológico poderá detectar raios. 2017. Disponível em: <<https://www.terra.com.br/noticias/climatempo/goes-16-vera-america-do-sul-com-maior-precisao,38ad0fab4d18ee9de0abf39ddea9a642v5eiy3xa.html>>. Acesso em: 10 jun. 2018.

CPTEC - INPE. **GEONETCast Americas.** Disponível em: <<http://satelite.cptec.inpe.br/geonetcast/br/>>. Acesso em: 13 jun. 2018.

CPTEC - INPE. **O QUE SE OBSERVA EM IMAGENS DE SATÉLITE GOES: UM POUCO DE FÍSICA.** Disponível em: <satelite.cptec.inpe.br/informacao/oqvgoes.jsp>. Acesso em: 09 jun. 2019.

EMBRAPA. **GOES - Geostationary Operational Environmental Satellite.** Disponível em: <https://www.cnpm.embrapa.br/projetos/sat/conteudo/missao_goes.html>. Acesso em: 08 jun. 2019.

EMBRAPA. **NOAA – National Oceanic Atmospheric Administration.** Disponível em: <https://www.cnpm.embrapa.br/projetos/sat/conteudo/missao_noaa.html>. Acesso em: 08 jun. 2019.

FERNANDES, Diego Simões. **UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE ASTRONOMIA, GEOFÍSICA E CIÊNCIAS
ATMOSFÉRICAS** DEPARTAMENTO DE CIÊNCIAS

ATMOSFÉRICAS**DIEGO SIMÕES FERNANDES** **Caracterização das Tempestades a partir dos canais Infravermelho e Vapor d'água do Satélite GOES 10 e 12.** 2010. 165 f. TCC (Graduação) - Curso de Instituto de Astronomia, Geofísica e Ciências Atmosféricas departamento de Ciências Atmosféricas, Universidade de São Paulo, São Paulo, 2010. Disponível em: <http://www.iag.usp.br/pos/sites/default/files/m_diego_s_f.pdf>. Acesso em: 09 jun. 2018.

FLORENZANO, Teresa Gallotti. **Os Satélites e Suas Aplicações.** São José dos Campos: Sindct, 2008. 50p.

INÁCIO, Lucélia Souza; GONÇALVES, Mariane Cechinel; IMIANOVSKY, Wagner Antonio. **APLICAÇÕES DE SATÉLI.** 2005. 41 f. TCC (Graduação) - Curso de Curso Técnico de Meteorologia, Centro Federal de Educação Tecnológica de Santa Catarina, Florianópolis, 2005.

MAGNUM. **A História do Python.** 2014. Disponível em: <<http://mindbending.org/pt/a-historia-do-python>>. Acesso em: 13 jun. 2019.

NOAA. **NOAA's roots reach back more than 200 years: We are America's environmental intelligence agency.** Disponível em: <<https://www.noaa.gov/our-history>>. Acesso em: 10 jun. 2019.

PRADO, Antonio Fernando Bertachini de Almeida; KUGA, Helio Koiti. **Fundamentos de Tecnologia Espacial.** São José dos Campos: Inpe, 2001.

SILVA, Ivan Nunes da; SPATTI, Danilo Hernane; FLAUZINO, Rogério Andrade. **Redes Neurais Artificiais:** Para engenharia e Ciências Aplicadas. São Paulo: Artliber, 2010. 395 p.

TEIXEIRA, Livia. **Desenvolvimento de material de estudo dos princípios de meteorologia e meio ambiente para estudantes, professores e meios de**

comunicações. Disponível em:

<<https://www.cptec.inpe.br/glossario.shtml#27>>. Acesso em: 8 jun. 2019.

YNOUE, Rita Yuri et al. **Meteorologia:** Noções básicas. São Paulo: Oficina de Textos, 2017. 40 p.